

# Teoria Estadística - Distribución Binomial

*Gonzalo Barrera Borla y Jesus Zapata*

*2 de Septiembre de 2018*

## Introducción

Sea  $\mathbb{X} = (X_1, X_2, \dots, X_n)$  un vector aleatorio tal que  $X_i \sim Bi(k, p) \forall i \in \{1, \dots, n\}$ , y  $X_i \perp X_j \forall i, j \in \{1, \dots, n\}$ . Es decir, que todas las  $X_i$  son independientes entre sí, están idénticamente distribuidas, y su función de distribución pertenece a la “familia binomial”

Si escribimos  $\theta = (k, p)$  la función de probabilidad puntual queda dada por

$$f(x; \theta) = \binom{k}{x} p^x (1-p)^{k-x}$$

La función de densidad conjunta, llamémosla  $\mathbf{p}(x_1, x_2, \dots, x_n; \theta)$  será entonces

$$\mathbf{p}(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = \left[ \prod_{i=1}^n \binom{k}{x_i} \right] \times p^{\sum_{i=1}^n x_i} \times (1-p)^{nk - \sum_{i=1}^n x_i}$$

Si convenimos en la notación  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  y  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ , podemos reescribir

$$\mathbf{p}(\mathbf{x}; \theta) = \left[ \prod_{i=1}^n \binom{k}{x_i} \right] \times p^{n\bar{x}} \times (1-p)^{n(k-\bar{x})}$$

## Estimadores

Consideraremos tres tipos de situaciones: - estimación del número de pruebas  $k$  con probabilidad de éxito  $p$  conocida, - estimación de  $p$  con  $k$  conocido, y - estimación de  $\theta = (k, p)$ , sin ningún parámetro conocido.

**De  $q(\theta) = k$**

Asumiendo que la probabilidad de éxito  $p$  de un ensayo individual es conocida, es razonable querer estimar el parámetro desconocido  $k$ , el número de ensayos efectuados, siempre el mismo para cada variable aleatoria  $X_i$

Lo intentaremos según el método de los momentos, usando los momentos de primer y segundo orden, y según el método de máxima verosimilitud.

**Momentos con  $g(x) = x$**

Sea  $g$  una función de  $\mathbb{R}$  en  $\mathbb{R}$ , luego el método de los momentos estima  $\theta$ , por el valor  $\hat{\theta} = \delta(\mathbb{X})$  que satisface la ecuación

$$\frac{1}{n} \sum_{i=1}^n g(X_i) = E(g(X_1) \mid \theta = \hat{\theta}) = E_{\hat{\theta}}(g(X_1))$$

Si usamos  $g(x) = x$ , y escribimos  $\theta = (\hat{k}, p)$  y sabiendo que  $E(X_i) = k \times p \ \forall i \in \{1, \dots, n\}$ , podemos afirmar que el estimador de  $k$  será el  $\hat{k}$  que satisfaga

$$\frac{1}{n} \sum_{i=1}^n X_i = \mathbb{E}(X_1 \mid \theta = (\hat{k}_{m_1}, p)) \Rightarrow \bar{X} = \hat{k}_{m_1} \times p \Rightarrow \boxed{\hat{k}_{m_1} = \frac{\bar{X}}{p}}$$

### Momentos con $g(x) = x^2$

Si en lugar de usar la función identidad para  $g$  utilizamos  $g(x) = x^2$  obtenemos un estimador relacionado al momento  $\hat{k}_{m_2}$  de segundo orden. Aquí será útil recordar que para toda variable aleatoria  $X$  con media y varianzas finitas,  $Var(X) = E(X^2) - [E(X)]^2$ :

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i^2 &= E(X_1^2 \mid \theta = (\hat{k}_{m_2}, p)) = E_{\hat{k}_{m_2}}(X_1^2) \\ \overline{X^2} &= Var_{\hat{k}_{m_2}}(X_1) + [E_{\hat{k}_{m_2}}(X_1)]^2 \\ \overline{X^2} &= \hat{k}_{m_2} p (1 - p) + [\hat{k}_{m_2} p]^2 \\ 0 &= \hat{k}_{m_2}^2 p^2 + \hat{k}_{m_2} p(1 - p) - \overline{X^2} \end{aligned}$$

Que es una ecuación cuadrática con coeficientes  $a = p^2$ ,  $b = p(1 - p)$ ,  $c = -\overline{X^2}$ . La expresión general de sus raíces nos da

$$\hat{k}_{m_2} = \frac{p(p-1) \pm \sqrt{p^2(1-p)^2 + 4p^2\overline{X^2}}}{2p^2} = \boxed{\frac{p-1 + \sqrt{(1-p)^2 + 4\overline{X^2}}}{2p}}$$

La conversión de  $\pm$  en  $+$  se justifica ya que  $k$  debe ser positivo, y  $p-1 < 0$ .

### Máxima Verosimilitud

Recordemos que el estimador de máxima verosimilitud se define como aquél que maximiza la función de probabilidad conjunta  $p$  (“función de verosimilitud”) de la muestra observada. En otras palabras, diremos que  $\delta(\mathbb{X}) = \widehat{g(\theta)_{mv}} = \hat{k}_{mv}$  es el estimador de máxima verosimilitud de  $g(\theta) = k$  si se cumple que

$$\mathbf{p}(\mathbf{x} \mid \theta = (\hat{k}_{mv}, p)) = \max_{\theta \in \Theta} \mathbf{p}(\mathbf{x} \mid \theta)$$

La forma tradicional de maximizar una expresión así, consiste en buscar  $\hat{k} : \frac{\partial \mathbf{p}(\mathbf{x}, \hat{k}, p)}{\partial k} = 0$ . El problema, es que  $\mathbf{p}$  incluye términos combinatorios de la forma  $\binom{k}{x_i}$ , con lo cual su derivada parcial respecto a  $k$  no es amistosa.

No es lo mismo afirmar que “el EMV no existe”, a decir que “el EMV existe pero es difícil de tratar algebraicamente”, que es una afirmación más precisa. Haciendo uso del lenguaje  $\mathbf{R}$ , podemos escribir una función equivalente a lo siguiente:

$$EMV(k) = \boxed{\hat{k}_{mv} = \operatorname{argmax}_{k \in \mathbb{N}_{\geq 1}} \mathbf{p}(\mathbb{X} \mid \theta)}$$

De  $q(\theta) = p$

**Momentos con  $g(x) = x$**

$$\frac{1}{n} \sum_{i=1}^n X_i = \mathbb{E}(X_1 \mid \theta = (k, \hat{p}_{m_1})) \Rightarrow \bar{X} = k \times \hat{p}_{m_1} \Rightarrow \boxed{\hat{p}_{m_1} = \frac{\bar{X}}{k}}$$

### Momentos con  $g(x) = x^2$

Seguiremos un procedimiento muy similar al utilizado para calcular  $\hat{k}_{m_2}$ , buscando  $\hat{p}_{m_2}$  que satisfaga:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i^2 &= E(X_1^2 \mid \theta = (k, \hat{p}_{m_2})) = E_{\hat{p}_{m_2}}(X_1^2) \\ \overline{X^2} &= Var_{\hat{p}_{m_2}}(X_1) + [E_{\hat{p}_{m_2}}(X_1)]^2 \\ \overline{X^2} &= k \hat{p}_{m_2} (1 - \hat{p}_{m_2}) + [k \hat{p}_{m_2}]^2 \\ 0 &= k(k-1) \hat{p}_{m_2}^2 + k \hat{p}_{m_2} - \overline{X^2} \end{aligned}$$

Tomando coeficientes  $a = k(k-1)$ ,  $b = k$ ,  $c = -\overline{X^2}$ , la expresión general de sus raíces nos da

$$\boxed{\hat{p}_{m_2} = \frac{-k \pm \sqrt{k^2 + 4k(k-1)\overline{X^2}}}{2k(k-1)}}$$

Al igual que en la estimación de  $\hat{k}_{m_2}$ , reemplazar  $\pm$  por  $+$  se justifica ya que  $p \in [0, 1]$ . También vale notar que este estimador sólo sirve si  $k > 1$ .

## Máxima Verosimilitud

A diferencia de  $\hat{k}_{mv}$ ,  $\hat{p}_{mv}$  es más ameno a la manipulación simbólica.

Como la función  $\ln(\mu)$  es monótona creciente, maximizar  $\mathbf{p}(\mathbf{x}, \theta)$  será equivalente a maximizar  $\ln \mathbf{p}(\mathbf{x}, \theta)$ . Luego el  $EMV(p)$  debe verificar  $\frac{\partial \ln \mathbf{p}(\mathbf{x}, k, \hat{p})}{\partial p} = 0$ . Calculemos la derivada parcial de  $\ln \mathbf{p}$ :

$$\begin{aligned} \frac{\partial \ln \mathbf{p}(\mathbf{x}, \theta)}{\partial p} &= \frac{\partial}{\partial p} \ln \left[ \left( \prod_{i=1}^n \binom{k}{x_i} \right) \times p^{n\bar{x}} \times (1-p)^{n(k-\bar{x})} \right] \\ &= \frac{\partial}{\partial p} \left[ \left( \sum_{i=1}^n \ln \binom{k}{x_i} \right) + n \bar{x} \ln p + n (k - \bar{x}) \ln (1-p) \right] \\ &= \frac{n\bar{x}}{p} - \frac{n(k-\bar{x})}{1-p} = \frac{n\bar{x}(1-p) - np(k-\bar{x})}{p(1-p)} \end{aligned}$$

Igualando a cero y reemplazando  $p = \hat{p}_{mv}$ ,  $\mathbf{x} = \mathbb{X}$

$$\begin{aligned} 0 &= \frac{\partial \ln \mathbf{p}(\mathbb{X}, (k, \hat{p}_{mv}))}{\partial p} = \frac{n\bar{X}(1-\hat{p}_{mv}) - n\hat{p}_{mv}(k-\bar{X})}{\hat{p}_{mv}(1-\hat{p}_{mv})} \\ 0 &= \frac{n}{\hat{p}_{mv}(1-\hat{p}_{mv})} \times \bar{X}(1-\hat{p}_{mv}) - \hat{p}_{mv}(k-\bar{X}) \\ 0 &= \bar{X} - \bar{X}\hat{p}_{mv} - \hat{p}_{mv} k + \bar{X}\hat{p}_{mv} \\ &\Rightarrow \boxed{\hat{p}_{mv} = \frac{1}{k}\bar{X}} \end{aligned}$$

Que coincide con el estimador de momentos de primer orden,  $\hat{p}_{m_1} = \hat{p}_{mv}$

De  $q(\theta) = \theta = (k, p)$

Intentaremos ahora estimar ambos parámetros de la distribución a la vez

### Método de los momentos

Indicaremos por  $\hat{\theta}_{m_{12}} = (\hat{k}_{m_{12}}, \hat{p}_{m_{12}})$  el estimador de momentos para ambos parámetros, que tendrá que cumplir:

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n X_i &= \bar{X} = E_{\hat{\theta}_{m_{12}}} (X_1) = \hat{k}_{m_{12}} \times \hat{p}_{m_{12}} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= \overline{X^2} = E_{\hat{\theta}_{m_{12}}} (X_1^2) = Var_{\hat{\theta}_{m_{12}}} (X_1) + [E_{\hat{\theta}_{m_{12}}} (X_1)]^2 = \hat{k}_{m_{12}} \hat{p}_{m_{12}} (1 - \hat{p}_{m_{12}}) + [\hat{k}_{m_{12}} \hat{p}_{m_{12}}]^2\end{aligned}$$

Cuya solución es

$$\hat{k}_{m_{12}} = \frac{\overline{X^2} + \bar{X} - \overline{X^2}}{\bar{X}} \quad ; \quad \hat{p}_{m_{12}} = \frac{\bar{X}^2}{\overline{X^2} + \bar{X} - \overline{X^2}}$$

### Máxima Verosimilitud

Al igual que con  $\hat{k}_{mv}$ , no hay una “expresión cerrada” de  $\hat{\theta}_{mv}$  que podamos reportar. Sin embargo, podemos definirlo (y computarlo en **R**) según:

$$EMV(\theta) = \boxed{\hat{\theta}_{mv} = \operatorname{argmax}_{\theta \in \Theta} \mathbf{p}(\mathbb{X} \mid \theta)} \quad , \quad \Theta = \{1, 2, \dots\} \times [0, 1]$$

## Comparación y análisis

### Error cuadrático medio

Recordemos que dado el estimador  $\widehat{q(\theta)} = \delta(\mathbb{X})$ , su error cuadrático medio es

$$ECM_{\theta}(\delta(\mathbb{X})) = E_{\theta}(\delta(\mathbb{X}) - q(\theta))^2 = Var_{\theta}(\delta(\mathbb{X})) + Sesgo^2 \text{ con } Sesgo = b(\delta(\mathbb{X})) = E(\delta(\mathbb{X})) - q(\theta)$$

Para determinar la bondad del estimador se comparan los ECM de cada estimador y el que tiene menor ECM es el mejor estimador, es decir,  $\delta^*$  será mejor estimador que  $\delta$  si y sólo si:

$$ECM_{\theta}(\delta^*) \leq ECM_{\theta}(\delta) \quad \forall \theta \in \Theta$$

De todos los estimadores que consideramos hasta ahora, los únicos que permiten calcular sencillamente la esperanza y varianza son  $\{\hat{p}_{m_1}, \hat{p}_{mv}, \hat{k}_{m_1}\}$ . Además, no se puede comparar los estimadores de  $p$  porque el de momentos como el de máxima verosimilitud son idénticos. De cualquier manera se puede determinar el ECM de los mismos.

### Estimadores de $q(\theta) = p$

Calcularemos primero el sesgo del estimador  $\delta = \hat{p}_{m_1} = \hat{p}_{mv}$ :

En nuestro caso:

$$b(\delta, q) = E_{\theta}(\delta(\mathbb{X}) - q(\theta)) = E_{\theta} \left[ \frac{1}{k} \left( \frac{1}{n} \times \sum_{i=1}^n X_i \right) - p \right] = \frac{1}{kn} E(X_1) - p = \frac{kp}{k} - p = 0$$

Por lo tanto el estimador es insesgado, y su ECM es igual a la varianza del estimador. En este caso,

$$Var_{\theta}(\delta) = Var_{\theta} \left[ \frac{1}{k} \times \frac{1}{n} \sum_{i=1}^n X_i \right] = \frac{1}{(kn)^2} Var_{\theta} \left[ \sum_{i=1}^n X_i \right] = \frac{1}{(kn)^2} \sum_{i=1}^n Var_{\theta}(X_i) = \frac{1}{(kn)^2} n k p (1-p)$$

$$ECM_{\theta}(\delta) = Var_{\theta}(\delta) = \frac{p(1-p)}{kn}$$

### Estimadores de $q(\theta) = k$

De manera análoga a lo expuesto para  $\hat{p}_{m_1}$ , podemos ver que  $\hat{k}_{m_1}$  es insesgado ya que  $E_{\theta}(\hat{k}_{m_1}) = k = q(\theta)$ . Similarmente, obtendremos que

$$ECM_{\theta}(\hat{k}_{m_1}) = Var_{\theta}(\hat{k}_{m_1}) = \frac{k(1-p)}{np}$$

### Consistencia

Sabemos que por la ley fuerte de los grandes números,

$$\overline{X} = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow E(X_1) \quad c.t.p.$$

Luego,

$$\frac{1}{k} \overline{X} \rightarrow \frac{1}{k} E(X_1) = q(\theta) = p \quad c.t.p.$$

y por lo tanto  $\frac{1}{k} \overline{X} = \hat{p}_{m_1} = \hat{p}_{mv}$  es un estimador fuertemente consistente de  $q(\theta) = p$ .

De manera análoga, pero reemplazando  $\frac{1}{k}$  por  $\frac{1}{p}$  podemos probar que  $\hat{k}_{m_1}$  es fuertemente consistente para  $q(\theta) = k$ .

### Estadísticos suficientes

Sea  $\mathbb{X}$  un vector aleatorio de dimensión  $n$  cuya distribución es  $F(\mathbf{x}, \theta)$  con  $\theta \in \Theta$ . Se dice que un estadístico  $T = r(X)$  es suficiente para todo  $\theta$  si la distribución de  $X$  condicional a que  $T = t$  es independiente de  $\theta$  para todo  $t$ .

Para encontrar el estadístico suficiente se utilizará el siguiente teorema

## Teorema de Factorización

Sea  $X$  un vector aleatorio con función de densidad o función de probabilidad puntual  $p(x, \theta), \theta \in \Theta$ . Entonces, el estadístico  $T = r(X)$  es suficiente para  $\theta$  si y sólo si existen dos funciones  $g$  y  $h$  tales que:

$$p(\mathbf{x}, \theta) = g(r(\mathbf{x}), \theta)h(\mathbf{x})$$

## Anexo 1: Código de simulaciones

```
library(tidyverse)
verosimilitud <- function(X) {
  function(tita) {
    sum(log(dbinom(X, size = tita[["n"]], prob = tita[["p"]]))))
  }
}

tita <- list(n = 50, p = 0.23)
muestra <- rbinom(100, size = tita[["n"]], prob = tita[["p"]])
ver1 <- verosimilitud(muestra)
espacio <- cross(list(
  n = 1:100,
  p = (1:100)/100
))

tibble(titon = espacio,
  vero = map_dbl(titon, ver1)) %>%
  transmute(
    n = map_dbl(titon, "n"),
    p = map_dbl(titon, "p"),
    vero) -> resumen

resumen %>% mutate(E = n*p) %>% arrange(desc(vero))
resumen %>%
  filter(near(n*p, 0.6)) %>%
  arrange(desc(vero))

resumen %>%
  ggplot(aes(n, p, z = vero)) +
  geom_contour(binwidth = 0.1)

resumen %>%
  ggplot(aes(n, p)) +
  geom_density2d()

espacio_vero
max_n <- 10000
map(espacio, ver1)
ver1(list(n = 50, p = 0.1))
data <- tibble(
  x = seq_len(max_n),
  y = map_dbl(x, ver1))
```

```

data %>%
  ggplot(aes(x, y)) +
    geom_line()

data %>% arrange(desc(y))

estimadores <- list(
  m1_p = function(X, n, ...) { mean(X) / n },
  m2_p = function(X, n, ...) {
    (n + sqrt(n^2 + 4*n*(n-1) * mean(X^2))
    ) / (2 * n * (n - 1))
  },
  m1_n = function(X, p, ...) { mean(X) / p },
  m2_n = function(X, p, ...) {
    (sqrt(p^2 - 2*p + 4*mean(X^2) + 1) + p - 1
    ) / (2 * p)
  },
  m12_n = function(X, ...) {mean(X)^2 / (mean(X)^2 + mean(X) - mean(X^2))},
  m12_p = function(X, ...) {(mean(X)^2 + mean(X) - mean(X^2)) / mean(X)},
  mv_p = function(X, p, ...) { mean(X) / p }
)

rango_p_final <- c(0, 0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 0.5, 0.7, 0.9, 0.97, 0.99, 0.997, 0.999, 1)
rango_p <- c(0, 0.01, 0.1, 0.5, 0.9, 0.99, 1)
rango_n_final <- round(exp(seq_len(9)), 0)
rango_n <- round(exp(seq_len(4)), 0)
rango_k <- rango_n
sims <- 1000

estimaciones_a_realizar <- cross_df(list(
  k = rango_k, estimador = names(estimadores))
)

df <- cross_df(list(n = rango_n, p = rango_p, sim_id = seq_len(sims))) %>%
  mutate(
    data = map2(n, p, ~rbinom(n = max(rango_k), size = .x, prob = .y))
  )

asistente_estimacion <- function(X, nombre_estimador, k, ...) {
  estimadores[[nombre_estimador]](X[seq_len(k)], ...)
}

resultados <- crossing(df, estimaciones_a_realizar) %>%
  mutate(valor = pmap_dbl(
    .l = list(X = data, nombre_estimador = estimador, k = k, n = n, p = p),
    .f = asistente_estimacion))

pryr::object_size(resultados)

resultados %>%
  filter(n == 20, p == 0.001, estimador %in% c("m1_p", "m2_p", "m12_p")) %>%
  ggplot(aes(valor, color = estimador)) +
  geom_freqpoly()

```

```

resultados %>%
  select(-data) %>%
  write_csv("resultados.csv")

resultados %>%
  group_by(n, p, k, estimador) %>%
  summarise(media = mean(valor)) %>%
    #varianza = sd(valor)) %>%
  spread(estimador, media) %>%
  View()

ggplot(aes(valor, color = k)) +
  geom_freqpoly() +
  facet_grid(n ~ p)

```